

DEEP REINFORCEMENT LEARNING — HW2



Q-learning vs SARSA — 問答記錄與實作計畫

課程	Deep Reinforcement Learning
作業編號	HW2
環境	Cliff Walking 4×12 Gridworld
演算法	Q-learning (Off-policy)、SARSA (On-policy)
線上展示	https://v901203.github.io/0415DRL_HW2/
技術棧	HTML / CSS / JavaScript (純前端)

一、環境描述 (Environment Description)

Q：本次作業使用什麼環境？

採用經典的格子世界 (Gridworld) 問題 — 「Cliff Walking」環境：

- 矩形網格： 4×12 (4 列、12 行)，共 48 個狀態
- 起點 (S)：左下角 (位置索引 36)
- 終點 (G)：右下角 (位置索引 47)
- 懸崖 (Cliff)：底部列第 37–46 格 (共 10 格)
- 踏入懸崖：獲得 **-100** 懲罰並立即重回起點，回合不終止
- 其他移動：每步 **-1**
- 到達終點 (G)：獲得 **-1** 並結束回合

Q：為什麼選用 Cliff Walking 作為比較環境？

此環境是 Sutton & Barto 《Reinforcement Learning》第 6 章的標準範例。

- **夠小**：易於視覺化，訓練速度極快 (瀏覽器即可執行)

- **夠典型**：懸崖機制天然放大 Q-learning（冒險）vs SARSA（保守）的行為差異
- **可驗證**：可與教科書圖表直接對照，確認實作正確性

二、問題設定（Problem Setting）

Q：狀態空間、動作空間、獎勵機制如何定義？

項目	定義	說明
狀態空間	$S = \{0, 1, \dots, 47\}$	所有 48 個格子位置
動作空間	$A = \{\text{上, 下, 左, 右}\}$	4 個離散動作，超出邊界停在原位
獎勵（一般）	$r = -1$	每步移動，鼓勵盡快到達終點
獎勵（懸崖）	$r = -100, s \leftarrow \text{起點}$	踏入懸崖，嚴重懲罰
終止條件	$s = 47$ （終點）	到達 G 則回合結束

Q：預設超參數設定為何？可以調整嗎？

預設值（符合作業要求）：

- 探索率 $\epsilon = 0.1$ （ ϵ -greedy：10% 機率隨機探索）
- 學習率 $\alpha = 0.5$ （每步更新幅度）
- 折扣因子 $\gamma = 0.9$ （未來獎勵的折扣比例）
- 訓練回合數 **500 回合**（介面可調整 100–2000）

介面提供四個即時滑桿，調整後重新訓練即可看到不同結果。

三、演算法實作 (Algorithm Implementation)

Q-learning (Off-policy TD Control)

Q：Q-learning 的更新公式與虛擬碼？

更新公式：

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \cdot \max_{a'} Q(s',a') - Q(s,a)]$$

Off-policy 的含義：更新目標取「下一狀態所有動作的最大 Q 值」，與實際選取的探索動作無關，因此學習的是**理論最優策略**。

```
// Q-learning Pseudocode (JavaScript 實作)
初始化 Q(s,a) = 0, 對所有 s ∈ S, a ∈ A
for 每個回合 episode = 1 ... N:
    s ← env.reset()                // 回到起點
    while 回合未結束:
        a ← ε-greedy(Q, s)         // 選動作 (探索 or 貪心)
        s', r ← env.step(a)        // 執行，得到下一狀態與獎勵
        Q(s,a) += α * (r + γ * max_a' Q(s',a') - Q(s,a)) // Off-policy 更新
        s ← s'                     // 狀態轉移
```

SARSA (On-policy TD Control)

Q：SARSA 的更新公式與虛擬碼？

更新公式：

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \cdot Q(s',a') - Q(s,a)]$$

On-policy 的含義：a' 也是由 ε-greedy 選出的實際動作，因此更新目標**包含了探索策略的影響**，學到的是「在 ε-greedy 策略下的安全行為」。

```
// SARSA Pseudocode (JavaScript 實作)
初始化 Q(s,a) = 0, 對所有 s ∈ S, a ∈ A
for 每個回合 episode = 1 ... N:
    s ← env.reset()
    a ← ε-greedy(Q, s)             // 回合開始就選好第一個動作
    while 回合未結束:
        s', r ← env.step(a)
        a' ← ε-greedy(Q, s')       // 選實際下一步動作
```

```
Q(s,a) += α * (r + γ * Q(s',a') - Q(s,a)) // On-policy 更新
s ← s' ; a ← a' // 同時更新狀態與動作 (SARSA 的關鍵)
```

Q：兩個演算法的核心差異在哪一行？

面向	Q-learning (Off-policy)	SARSA (On-policy)
更新目標	$\max_a Q(s',a')$	$Q(s',a'), a' \sim \epsilon\text{-greedy}$
目標策略	貪心最優 (π^*)	行為策略 (含探索)
學習的策略	理論最優路徑	實際安全路徑
收斂至	最優 Q^*	$\epsilon\text{-greedy}$ 策略的最優 Q

四、結果分析 (Results Analysis)

Q：學習曲線呈現出什麼現象？

- **Q-learning (紅線)**：初期因常掉崖獎勵極低，後期快速收斂至 $-13 \sim -20$ ，但 ϵ 探索仍偶爾造成掉崖（波動較大， σ 較高）
- **SARSA (青線)**：收斂後曲線更平滑，標準差 σ 更小，但最終均值可能略低於 Q-learning（路徑較長）
- SARSA 通常在更少回合（約 50–100）內達到穩定；Q-learning 有時需 200+ 回合

Q：步數曲線 (Steps per Episode) 說明了什麼？

- 初期兩者步數均高（頻繁掉崖 → 重置 → 累積大量步數）
- 收斂後：Q-learning ≈ 13 步（最短路徑），SARSA $\approx 15\text{--}17$ 步（繞道安全路徑）
- 步數越少代表策略越接近最優；但「最少步數」在 ϵ 探索下反而產生更多風險（Q-learning 的困境）

Q：最終策略 (Policy) 視覺化結果如何解讀？

策略格子以箭頭顯示每個狀態的貪心動作，並以虛線標記最優路徑：

Q-learning (冒險型)：箭頭顯示代理學會沿懸崖最底部邊緣前進（列 3，行 0 → 11），共 13 步。即使訓練時偶爾因探索掉崖，Off-policy 更新仍將這條路視為最優。

SARSA (保守型)：代理學會先往上移 1–2 格遠離懸崖，再向右，最後往下到終點，共 15–17 步。On-policy 更新「記住」了探索帶來的掉崖風險，主動避開危險區域。

此差異完全符合 Sutton & Barto Example 6.6 的理論預測。

Q：Q-Table 熱力圖如何解讀？

熱力圖以色階顯示各狀態的 $\max_a Q(s,a)$ （狀態最大價值）：

- **深藍**：低價值（遠離終點或高風險狀態）
- **黃色**：高價值（靠近終點且路徑安全的狀態）

差異觀察：Q-learning 的熱力圖中，懸崖正上方的格子仍有**較高價值**（因其視為最優路徑）；而 SARSA 的熱力圖中，這些格子的價值被降低，高價值區域分佈更廣（保守估計）。

五、理論比較與討論 (Theory)

Q：Off-policy 與 On-policy 的本質差異是什麼？

概念	Off-policy (Q-learning)	On-policy (SARSA)
行為策略	ϵ -greedy (用於採集資料)	ϵ -greedy (用於採集與更新)
目標策略	貪心策略 (π^*)	與行為策略相同
探索影響	不影響 Q 值更新目標	直接影響 Q 值更新目標
可複用舊資料	✓ 可 (Experience Replay)	✗ 不可
Cliff Walking 行為	緊貼懸崖 (風險高)	遠離懸崖 (安全)

Q： ϵ -greedy 探索對兩個演算法各有什麼不同影響？

對 Q-learning： ϵ 探索影響「資料收集」但不影響 Q 值更新目標 (目標永遠是 max Q)。即使訓練中因探索掉崖，最終學到的策略仍是「貪心最優」。

對 SARSA： ϵ 探索直接影響更新目標 $Q(s',a')$ 。懸崖旁若隨機選到「向下」這個動作，就會得到 -100 的反饋並更新到 Q 表，使得 SARSA 學會遠離危險。 ϵ 越大，SARSA 越保守。

六、結論 (Conclusion)

Q：哪種方法收斂較快？哪種較穩定？

指標	Q-learning	SARSA
收斂速度	較慢 (約 200-400 回合)	✓ 較快 (約 50-100 回合)
穩定性 (σ)	較高波動 (緊貼懸崖)	✓ 較低波動 (安全路徑)
最終路徑步數	✓ 較少 (13 步最優)	較多 (15-17 步)
訓練期安全性	風險較高 (偶爾掉崖)	✓ 風險較低

部署性能 ($\epsilon=0$)

✔️ 更高效 (最短路徑)

略次 (路徑較長)

Q：何種情境應選 Q-learning 或 SARSA？

選 **Q-learning** 的情境：

- 可以離線訓練後再部署（部署時關閉 ϵ 探索）
- 追求最少步數/最高累積獎勵的最優策略
- 有充足的歷史資料可複用（Off-policy 支援 Experience Replay）
- 遊戲 AI、棋盤類問題等容忍訓練失敗的場景

選 **SARSA** 的情境：

- 訓練與部署在同一環境中進行（真實機器人、工廠控制）
- **安全敏感場景**：機器人、自駕車、醫療設備——訓練期間不能有高風險行為
- ϵ 無法設為 0 的場景（需持續探索應對環境變化）
- 追求穩定、低波動的學習過程

✦ 教科書結論 (Sutton & Barto, Reinforcement Learning, 2nd Ed., Chapter 6, Example 6.6)

「Q-Learning learns the optimal policy. SARSA learns the safe policy.

Which is "better" depends on the deployment context.

On-policy SARSA is better *during* learning; Off-policy Q-learning is better *at test time*.」

這是 On-policy vs Off-policy 方法在安全與最優性之間取舍的經典示範。

附錄：實作計畫與功能清單 (Implementation Plan)

A. 核心程式架構 (script.js)

- **CliffWalkingEnv**：環境類別，封裝 `reset()` / `step()` 邏輯
- **makeQTable / epsilonGreedy / maxQ**：Q 表工具函數
- **runQLearning(params)**：回傳 { Q, rewards[], steps[] }
- **runSARSA(params)**：回傳 { Q, rewards[], steps[] }
- **greedyPath(Q)**：從訓練後 Q 表提取最優路徑
- **drawLineChart()**：通用折線圖（學習曲線 & 步數曲線共用）
- **drawPolicyCanvas()**：策略箭頭格子 + 虛線路徑
- **drawQHeatmap()**：Q-Table 狀態價值熱力圖 ★ 新增
- **updateAnalysis()**：自動生成文字分析報告

B. 視覺化功能總覽

功能	Canvas ID	說明
 學習曲線	learning-chart	每回合累積獎勵，10-ep 滑動平均
 步數曲線	steps-chart ★	每回合步數，觀察收斂後步數穩定化
 策略格子	q/s-policy-canvas	箭頭 + 最優路徑虛線 + 步數標號
 Q-Table 熱力圖	q/s-heatmap-canvas ★	深藍→黃色階顯示狀態價值分布
 環境預覽	env-grid (HTML div)	靜態格子，S/G/☹️ 標記

C. 分析報告自動生成指標

- 最終平均獎勵（最後 100 回合均值）
- 收斂回合數（50 回合滑動均值達 -30 門檻的首個回合）
- 貪心策略最短路徑步數
- 獎勵標準差 σ （穩定性指標）
- 自動文字結論（比較收斂速度、穩定性、適用場景）

D. UI 與部署

- 參數滑桿： ϵ 、 α 、 γ 、Episodes（即時顯示數值）
- 異步訓練（async/await），訓練時不凍結 UI，含進度條
- 響應式排版（RWD），支援平板 / 手機
- 暗色 Glassmorphism 主題；Google Fonts Inter
- 部署：GitHub Pages 自動部署，push 後約 2 分鐘生效

Deep Reinforcement Learning HW2 — Cliff Walking: Q-learning vs SARSA | 線上展示：
https://v901203.github.io/0415DRL_HW2/ | 列印建議：A4、邊距 10mm、背景圖形開啟